

HACKATHON INTERNACIONAL - NIVEL AVANZADO

HEALTHSIGNAL LATAM

Guia tecnica oficial del participante - RISA Data V1.0

Entidad retadora: Talento TECH

Escenario: Red Integrada de Salud Avanzada - RISA (ficticia)

Dataset: RISA Data V1.0

Reto: HealthSignal LATAM - Anticiparse al riesgo

Proposito del documento

Esta guía acompaña el desafío oficial y el dataset RISA Data V1.0. Define el escenario, la lógica de los datos, las dificultades técnicas, las capacidades que debe demostrar la solución, la estructura de entrega y las reglas de trazabilidad. No contiene respuestas de evaluación, Gold Standard ni casos ocultos.

Principio central

Transformar datos heterogéneos de salud en señales oportunas y priorizadas, sustentadas en evidencia disponible en el momento de decisión, robustas frente a calidad y contexto, y trazables hasta los registros fuente.

1. Escenario RISA y problema operativo

- RISA es una red de salud ficticia latinoamericana que integra hospital de mayor complejidad, clínica especializada, atención primaria, monitoreo domiciliario, laboratorios y telemonitoreo.
- El problema no es la ausencia de datos, sino su fragmentación, heterogeneidad, frecuencia variable, latencia y calidad desigual.
- La pregunta operativa es: cómo reconocer a tiempo que una combinación de datos merece atención, sin convertir cada variación en una alerta.
- Todos los pacientes y registros son sintéticos; no representan personas reales.

2. Arquitectura conceptual de RISA Data V1.0

- La data combina maestros, información clínica, observaciones fisiológicas, wearables, laboratorio, contexto, dispositivos y conectividad.
- Las fuentes no necesariamente comparten granularidad ni frecuencia. Los equipos deben reconstruir la historia temporal del paciente a partir de múltiples tablas.
- Los identificadores originales deben conservarse para permitir joins, auditoría y trazabilidad.
- Los catálogos de variables, unidades y fuentes deben revisarse antes de modelar.

3. Semántica temporal y operacional

- Debe distinguirse entre el momento en que ocurre un evento y el momento en que la información está disponible para el sistema.
- En laboratorio, la muestra puede existir antes de que el resultado esté disponible; en wearable, la observación puede sincronizarse después.
- Para una decisión en T solo puede utilizarse información con $T_{\text{available}} \leq T$.
- Una buena solución diferencia timeline fisiológico y timeline operacional cuando sea pertinente.

4. Calidad de datos, temporalidad y trampas técnicas

- RISA no es un dataset perfectamente limpio por diseño. La limpieza forma parte del problema analítico.
- El equipo debe considerar missingness, ruido/artefactos, duplicados/retransmisiones, unidades, calidad de señal, contexto y desalineación temporal.
- Missing no equivale a cero ni a normal. La imputación debe ser defendible y debe diferenciar dato observado de dato estimado.
- Un outlier no equivale automáticamente a riesgo: debe contrastarse con persistencia, contexto, calidad, histórico y otras variables.
- Debe evitarse temporal leakage tanto en features como en baselines y validación.

5. Estrategia técnica recomendada

- Ruta sugerida: comprender -> ingerir -> validar -> normalizar -> ordenar temporalmente -> contextualizar -> construir evidencia -> detectar -> priorizar -> explicar -> validar.
- No es obligatorio cargar todo simultaneamente. Es valido desarrollar primero un pipeline correcto sobre una muestra y luego escalarlo.
- Se recomienda separar RAW, CLEAN, FEATURES y MODEL para preservar auditabilidad.
- Las features pueden incluir agregaciones, pendientes, persistencia, desviaciones respecto al baseline, contexto y calidad.
- RISA no impone machine learning: reglas, estadística, ML, deep learning, modelos temporales o sistemas híbridos son validos si estan justificados.

6. Capacidades que debe demostrar la solución

- Detección: identificar senales relevantes, no solo valores fuera de rango.
- Anticipación: producir una decisión en un momento útil sin utilizar información futura.
- Priorización: ordenar pacientes/senales de forma operativa y justificar por que A esta antes que B.
- Explicabilidad y trazabilidad: mostrar que ocurrió, cuando, con que evidencia y por que se asigno esa prioridad.
- Robustez: gestionar razonablemente ruido, missingness, calidad, contexto, latencias y heterogeneidad.
- Resultado observable: el evaluador debe poder inspeccionar paciente, momento, prioridad/score, evidencia y explicación.

7. Requisitos técnicos de entrega

- Componentes obligatorios: solución funcional; código fuente o artefacto ejecutable; README.md; results/signals.csv; results/evidence.csv; arquitectura técnica de máximo 5 páginas; dependencias/configuración reproducible.
- Debe existir un punto de entrada claro y las rutas de datos no deben depender de una ruta rígida del computador del participante.
- Los CSV de salida deben ser UTF-8, separados por coma y corresponder a la misma versión final de la solución.
- El pitch final no forma parte de la métrica técnica oficial.

8. Evidencia, explicabilidad y trazabilidad

- La cadena esperada es dato -> evidencia -> señal -> prioridad -> explicación, manteniendo también la ruta inversa para auditoría.
- Cada señal debe vincularse con evidencia concreta. La evidencia puede tener rol PRIMARY, SUPPORTING, CONTEXT o QUALITY.
- Las features derivadas son válidas, pero las señales importantes deben poder trazarse razonablemente hacia registros originales.
- Los LLM pueden transformar evidencia estructurada en explicaciones, pero no inventar hechos, mediciones ni antecedentes.
- Una explicación fuerte conecta comportamiento observado, tiempo, contexto, calidad y decisión.

9. Reglas de uso y límites

- Los archivos oficiales de RISA Data V1.0 se consideran inmutables. Pueden crearse copias, bases derivadas, Parquet, features, índices o embeddings.
- Modelos preentrenados, APIs y servicios externos pueden utilizarse si las reglas generales del evento lo permiten y su función se documenta.
- El reto no exige diagnóstico ni prescripción. La solución apoya identificación, priorización y revisión.

- El Gold Standard, casos CORE, hard negatives oficiales, ventanas y rankings esperados son confidenciales.
- No existe numero obligatorio de senales, pacientes prioritarios, threshold oficial ni algoritmo obligatorio.
- La entrega final debe ser reproducible y los resultados estructurados deben provenir del pipeline presentado.

7.1 Esquema oficial de signals.csv

Campo	Oblig.	Regla principal
signal_id	Si	Identificador unico de la senal
patient_id	Si	ID existente en RISA
decision_datetime	Si	Instante en que existe evidencia suficiente
risk_score	Si	Numerico entre 0 y 1
priority_level	Si	LOW / MEDIUM / HIGH / CRITICAL
confidence_score	No	Si se usa, entre 0 y 1
evidence_start	Si	Inicio de ventana principal
evidence_end	Si	Fin de ventana; <= decision_datetime
explanation	Si	Justificacion breve y verificable
model_version	Si	Version que produjo el resultado

7.2 Esquema oficial de evidence.csv

Campo	Oblig.	Regla principal
signal_id	Si	FK hacia signals.csv
source_file	Si	Archivo fuente de RISA
record_id	Si	Identificador original del registro
variable_code	No	Variable relacionada cuando aplique
event_datetime	Si	Momento del fenomeno
available_datetime	Si	Momento en que la evidencia estaba disponible
evidence_role	Si	PRIMARY / SUPPORTING / CONTEXT / QUALITY
contribution	No	Peso o contribucion documentada

10. Checklist final del participante

- ☐ Uso la version oficial de RISA Data V1.0 y conservo IDs originales.
- ☐ Revise unidades, missingness, duplicados, calidad y heterogeneidad temporal.
- ☐ Mi pipeline evita temporal leakage y no usa evidencia disponible despues de decision_datetime.
- ☐ Cada senal tiene score, prioridad, ventana, explicacion, version y evidencia asociada.
- ☐ Cada available_datetime de evidence.csv es menor o igual al decision_datetime de su senal.
- ☐ Puedo explicar por que un paciente aparece antes que otro.
- ☐ Existe una solucion funcional y un punto de entrada claro.
- ☐ README, dependencias, arquitectura, signals.csv y evidence.csv estan completos.
- ☐ Ejecute validate_submission.py y el formato finaliza sin errores.
- ☐ Una persona ajena al desarrollo puede comprender que paciente priorizamos, cuando, por que y con que evidencia.

Regla de cierre

Si un evaluador no puede ejecutar, reconstruir o verificar una señal, esa señal no esta completamente demostrada.